BrainAgenticthon 2026 | Medical AI Workstream

الخطة الكاملة: Medical AI للمسابقة

عبدالرحمن + رؤى | Detection · Segmentation · Spatial · Classification · Offline

عبدالرحمن + رؤى | إصدار 15 أكتوبر 2026

نطاق المستند: عمل عبدالرحمن ورؤى فقط: البيانات، Classification، Spatial/Segmentation، Detection، Calibration، تقييم الموديلات وتسليم المخرجات لباقي الفريق. **لا يتضمن تنفيذ Agentic AI أو Backend/Web** الخاص بفدوى ورند، لكنه يعرّف عقود الربط التي يحتاجونها.

1. ما تطلبه المسابقة الرسمية وما يقع ضمن مسؤوليتنا

المعيار الرسمي	الوزن	واجبنا المباشر
A Detection	15%	Abnormal vs Normal مع calibrated probability وAUROC وSensitivity@90%Specificity وECE
B Spatial characterization	20%	Lesional: 3D masks؛ Non-lesional: regional volumetry + explanation map؛ قياس Dice/HD95 حيث ينطبق
C Classification	20%	احتمالات الفئات المغلقة؛ Macro-F1 وBalanced Accuracy وper-class AUROC وCalibration
D Clinical report	10%	مسؤولية الفريق الآخر؛ نوفر evidence provenance وقياسات صحيحة
Efficiency	5%	Inference time وGPU memory وfailure rate على الجزء الطبي
Clinical relevance	10%	Masks وخرائط تفسير وأحجام وثقة قابلة للفهم
Innovation	10%	تجهيز واجهات موثقة، دعم verification وتكرار النتائج
Pitch/Demo	10%	تأمين مخرجات علمية ثابتة لحالات unseen
Bonus	حتى +5%	≤3 core categories + hallucination target + <60 sec + calibrated uncertainty؛ لا نعد بها دون قياس

تسمح الوثيقة بالتدريب على بيانات MRI أو بيانات طبية أخرى، لكن الاختبار المحجوب سيكون 3D MRI؛ لذلك يجب أن يستطيع مسار الاستدلال العمل دون مدخلات إضافية إلزامية.

2. مصادر البيانات - ماذا نملك وماذا ينقصنا؟

الداتا	تخدم ماذا؟	حدودها
MSD Task01_BrainTumour (موجودة)	Glioma MRI segmentation + spatial measurement	لا تحتوي Healthy Controls، ولا تكفي لتصنيف كل أمراض المسابقة
BraTS 2024 (عند توفر الوصول)	Glioma / Meningioma / Metastasis بحسب المسار الفرعي	تختلف Labels والموداليتي بين المسارات؛ شروط وصول واستخدام
OASIS أو ADNI	Alzheimer's / controls	يحتاج تدقيق ترخيص وتسميات مناسبة؛ مرض غير آفي ويحتاج Morphometry
PPMI / ABIDE	Parkinson's / ASD	إضافات عالية المخاطر زمنيًا، لا نعِد بتغطيتها قبل تدريب وقياس

قرار تنفيذي: نبدأ بإنجاز Glioma Spatial Pipeline علمي على MSD، ونبحث بالتوازي عن بيانات Normal وفئات أورام إضافية مع توثيق الوصول. لا نبني Detector طبيعي/غير طبيعي باستخدام بيانات Glioma فقط ثم ندّعي أنه عام.

3. معمارية الجزء الطبي المعتمدة

```
MRI input (NIfTI volume + optional metadata)
   |
[Data validation / preprocessing]
   |
[Detection: abnormal vs normal, calibrated]   -> detection.json
   |  evidence shared forward
[Spatial: nnU-Net lesion mask OR regional morphometry]
   |  -> mask.nii.gz OR morpho.json + explanation map
[Classification: MRI + detection + spatial features]
   |  -> classification.json (supported labels + uncertainty)
[Evidence export + model provenance + QC flags]
   |
Validated local artifacts -> other team reporting / agent modules
```

بالنسبة لتتابع A→B→C: لا نستخدم قرار Detection الحاد لإيقاف Spatial/Classification تلقائيًا، لأن False Negative قد يمنع كشف آفة؛ مرر احتمالية المرحلة ومؤشرات الجودة، واسمح بإجراء Spatial مناسب وفق بروتوكول واضح.

4. الأدوات المعتمدة - أداة أساسية لكل عمل

الوظيفة	الأداة	الرابط
فحص NIfTI	NiBabel + NumPy	https://nipy.org/nibabel/

الوظيفة	الأداة	الرابط
Preprocessing / Training	PyTorch + MONAI	https://monai.io/
Lesion segmentation	nnU-Net v2	https://github.com/MIC-DKFZ/nnUNet
Anatomical volumetry	SynthSeg (عند بيانات مناسبة)	https://github.com/BBillot/SynthSeg
مقاييس التصنيف	scikit-learn	https://scikit-learn.org/
فحص MRI بصريًا	3D Slicer	https://www.slicer.org/
كتابة الكود ومراجعته	Antigravity + Claude Thinking	https://antigravity.google/
تشغيل وتسليم دون شبكة	Docker (بالتكامل لاحقًا)	https://www.docker.com/

الخيارات هذه توصيات هندسية، وليست دليلًا على أن أوزانًا جاهزة تغطي جميع فئات المسابقة. جودة النتائج تعتمد على الـdataset والـweights والاختبار.

5. المراحل بالتفصيل + Acceptance Criteria

المرحلة 0 - تثبيت نطاق البيانات وعقود المخرجات

- تسجيل label mapping، modality order، Dataset version، الترخيص، عدد الحالات، وطريقة فتحها.
- إنشاء manifest وsplits قابلة لإعادة الإنتاج باستخدام random seed موثّق.
- تعريف schema مبدئي للنتائج مع فدوى ورند دون تنفيذ Modules الخاصين بهما.
- Done: يستطيع الطرف الآخر قراءة ملفات Mock Schema فارغة من دون استدعاء موديل.

المرحلة 1 - Dataset Audit & Leakage Control

- تشغيل validate_all_cases.py على 484 حالة تدريب كما هو مذكور في manifest.
- فحص Shapes وAffines وVoxel Spacing وLabels وNaN/Inf وملفات تالفة.
- مراجعة بصريّة لعينة ممثلة، والاحتفاظ بالصور الأصلية دون تعديل.
- بناء Train/Val Split على مستوى المريض/الحالة مع توثيق أي IDs غير موثوقة.
- Done: validation_report.json + dataset_inventory.csv + documented split وQC notes.

المرحلة 2 - MRI Preprocessing

- قراءة الأربع modalities حسب dataset.json؛ لا تعكس ترتيب القنوات.
- تحديد Orientation وSpacing المستهدفين، وإجراء Resampling للصور باستيفاء continuous وللـMasks بـnearest-neighbor.
- Intensity normalization داخل brain foreground لكل modality مع التعامل مع حالات zero-variance.
- حفظ inverse transforms / affine لرجوع Masks إلى فضاء الصورة الأصلية عند التصدير.

- Done: إعادة بناء الحالة بعد التحويل دون اختلاف ملحوظ بين الصورة والقناع، واختبارات deterministic.

المرحلة 3 - Tumor Segmentation Baseline

- تحويل MSD إلى صيغة nnU-Net v2 مع تسمية القنوات والملصقات حسب متطلبات الإصدار المستخدم.
- تحديد label definitions من dataset.json، ثم بناء WT/TC/ET عبر mapping مكتوب ومختبر؛ لا نفترض ترميز BraTS الآخر.
- تشغيل baseline وتوليد 3D probability maps وhard masks، وقياس Dice وHD95 لكل منطقة مناسبة.
- إخراج mask.nii.gz بإحداثيات متوافقة مع مدخلات المسابقة، وتوثيق runtime والذاكرة.
- Done: نموذج فعلي مدرّب أو pretrained مُتحقق منه، مع Validation metrics لا أرقام مدّعاة.

المرحلة 4 - Detection

- تجميع Positive + Healthy/Normal datasets حقيقية مع تقارب معقول في Modalities والموقع والتوزيع.
- استخدام 3D DenseNet121 كنقطة بداية، أو اعتماد baseline آخر بعد اختبار مقارن موثّق.
- منع التسرب والتعلم من dataset source بدل المرض عبر site-aware checks قدر الإمكان.
- معايرة النتائج على Validation (temperature scaling / isotonic) وفق ملاءمة البيانات).
- Done: AUROC وSensitivity at 90% Specificity وECE وconfidence calibration report.

المرحلة 5 - Disease Classification

- تحديد الفئات المدعومة فعليًا بالبيانات: Normal-, Glioma, Meningioma, Metastasis, Alzheimer's, FCD, Post stroke, Parkinson's, ASD, Uncertain/Other.
- بناء classifier تتغذى مدخلاته على MRI وميزات مراحل Detection/Spatial مع Feature Contracts واضحة.
- عدم نسبة probabilities موثوقة لفئة لم تدرب أو تختبر؛ حالات خارج التغطية تذهب إلى uncertainty/unsupported policy.
- تقييم Macro-F1 وBalanced Accuracy وper-class AUROC وcalibration مع Confusion Matrix.
- Done: classification.json واضح ويوثق coverage لكل فئة، مع benchmark لكل فئة مدعومة.

المرحلة 6 - Regional Volumetry & Explainability

- استخدام SynthSeg على الصور المناسبة لإنتاج Regional Volumes وQA لأنسجة الدماغ.
- إذا كان المسار مرضًا غير آفي، ننتج morpho.json مع وحدات واضحة (ml / mm^3) وexplanation map.
- لا نحول Morphometric Differences إلى تشخيص مرضي مؤكد دون Dataset/Model صالح.
- توليد Saliency للـClassification بحذر مع اختبار استقراره؛ لا نقول إن Heatmap تساوي Ground Truth.
- Done: تعود النتائج إلى reference space ولها artifacts يمكن للطرف الآخر استعراضها.

المرحلة 7 - Model Evaluation & Responsible AI

- تجارب Validation ثابتة + bootstrap intervals + per-class metrics + Confusion Matrix إن أمكن.

- فحص Fairness/Generalization حسب sex/age/site حين تتوفر metadata المسموحة؛ توثيق المفقود بدل ملء قيم افتراضية.
- اختبار زمن الاستدلال وذاكرة GPU واستهلاك RAM وfailure rate على أكثر من حالة.
- تعقب model provenance وأرقام الإصدارات والتحويلات، وإخراج evidence IDs بدل النصوص الحرة.
- Done: ملف metrics.json وreport عن القيود والفشل وعدم اليقين.

المرحلة 8 - Offline Handoff

- تجميد الأوزان محليًا مع hashes والتحقق من سلامتها.
- تصدير واجهة Python CLI تقرأ MRI وتكتب المخرجات إلى output directory محدد.
- عدم تحميل dependencies أو model weights أثناء inference؛ اختبار حقيقي دون شبكة.
- تحديد failures بوضوح: invalid MRI, missing modality, out-of-distribution, unsupported disease.
- Done: Case جديد يُعالج محليًا وبشكل reproducible، أو يفشل بفشل واضح غير مختلق.

6. عقود الربط: ماذا نعطي لفدوى ورند؟

هذه **أمثلة داخلية مقترحة** وليست الـSchema الرسمي النهائي الذي لم تتضمنه وثيقة المسابقة بشكل حقل-بحقل. يجب تأكيدها أو تعديلها إذا أعلن المنظمون قالبًا رسميًا.

```
detection.json
{
  "case_id": "case_001",
  "abnormal_probability": 0.82,
  "prediction": "abnormal",
  "calibration_method": "temperature_scaling",
  "model_version": "detector_v1",
  "qc_flags": []
}
```

```
classification.json
{
  "case_id": "case_001",
  "class_probabilities": {
    "Normal": 0.03, "Glioma": 0.78,
    "Meningioma": 0.07, "Metastasis": 0.05,
    "Alzheimer's": 0.01, "FCD epilepsy": 0.01,
    "Post-stroke lesion": 0.01, "Parkinson's": 0.01,
    "ASD": 0.01, "Uncertain/Other": 0.02
  },
  "model_version": "classifier_v1",
  "supported_labels": ["Glioma"]
}
```

الأرقام في المثالين أعلاه **اصطناعية لتوضيح شكل البيانات فقط**. ممنوع استخدام هذه الأمثلة كتنبؤ طبي حقيقي أو اعتبار supported_labels دلالة على أداء النموذج. تصميم closed-set probabilities لحالات خارج التغطية يحتاج Policy رسمية واضحة قبل التسليم.

```
spatial outputs
  mask.nii.gz   # lesion pathology, in documented input space
  OR morpho.json # regional values (e.g. mm3)
  saliency.nii.gz or other documented explanation map
  evidence_manifest.json # case_id, model, transform, source links
```

7. Metrics مطابقة للتقييم

Task	Metrics	إرشادات حساب دقيقة
Detection	AUROC, sensitivity @ 90% specificity, ECE	حساب Threshold من Validation فقط، مع تقرير حجم العينة وCI إن أمكن
Spatial	Lesion-wise Dice, HD95 by sub-region	التعامل مع Empty Masks صراحة؛ التأكد من spacing والـlabel remapping
Classification	Macro-F1, balanced accuracy, per-class AUROC, calibration	تحسب على فئات الاختبار المدعومة، وتعرض تفاصيل الفئات غير المتوفرة
Efficiency	% sec/case, peak GPU MB, failure	تحديد الـhardware والـbatch size والـpre/post-processing المشمول
Fairness	group-wise metrics	حسب sex/age/site عند توافر Metadata؛ لا تخمّن بيانات غير موجودة

8. Responsible AI / Offline - شروط لا نساوم عليها

- لا APIs خارجية أثناء التشغيل، ولا cloud inference، ولا تنزيل تلقائي لأوزان.
- لا حفظ صور أو بيانات مرضى ضمن سجلات دائمة؛ artifacts مؤقتة ومسار الحذف موثق.
- كل تنبؤ قابل للتتبع إلى Model Version وInputs/Transforms ومقاييس Validation.
- Calibrated confidence لا تُستنتج من softmax وحده دون اختبار.
- لا claims عن فئات لم تُدرَّب أو تُختبر.
- المشاركة في traceable reasoning تتم عبر evidence IDs ونتائج منظمة، لا مبررات مولدة بحريّة.
- نجهز مخرجات تسمح لطبقة Verification باكتشاف التناقضات، دون تنفيذ Agent الخاصة بفدوى.

9. تقسيم عمل عبدالرحمن ورؤى - دون فصل المسؤولية

عبدالرحمن	رؤى	مسؤولية مشتركة
+ Data audit + MRI preprocessing training manifests	+ Mask mapping + nnU-Net Visual QC	مراجعة Splits + منع Leakage
Detection and class calibration experiments	Spatial metrics + SynthSeg experiments	دمج خصائص Detection/Spatial في Classifier
Training logs and baseline metrics	Segmentation QA and exports	End-to-end tests + Handoff schemas

10. خطة الأيام من الآن إلى تسليم Prototype

التاريخ	أولوية مشتركة	مخرج ملموس
15 أكتوبر	تأكيد التسجيل، فحص كل البيانات، إصدار تقرير QC	validation_report.json
16-17 أكتوبر	Splits + preprocessing + nnU-Net conversion	preprocessed examples + dataset manifest
18-20 أكتوبر	Segmentation baseline + evaluation	weights + masks + Dice/HD95
21-23 أكتوبر	Detection ببيانات حقيقية وCalibration	detector + metrics + detection.json
24-25 أكتوبر	Classification للفئات التي تتوفر لها بيانات	classifier baseline + class metrics
26 أكتوبر	SynthSeg/volumetry إن توفرت موارد وبيانات مناسبة	morpho artifacts أو توثيق سبب التأجيل
27 أكتوبر	Integration of A→B→C + CLI + schemas	one-case end-to-end pipeline
28 أكتوبر	offline test + runtime + fairness report	benchmark log + failure tests
29 أكتوبر	handoff وتدقيق جميع المخرجات	frozen reproducible deliverable
30 أكتوبر	Prototype submission حسب الموعد الرسمي	containerized prototype عبر الفريق

> خطة مضغوطة وعالية المخاطرة لأن فترة التسليم قصيرة؛ إذا تعذر الحصول على بيانات Normal وفئات أخرى، لا نزوّر تغطية. نوثّق نطاق الـBaseline ونتفاوض مع الفريق على أولوية علمية قابلة للدفاع.

11. أول 6 Prompts لـAntigravity - واحد في كل مرة

Data audit | 01

```
Implement a read-only, offline dataset audit for MSD Task01_BrainTumour, verify MRI/mask shape, affine, four channels, labels 0-3, data integrity, and export machine-readable reports. Do not train or modify patient files. Include tests.
```

Preprocessing | 02

```
Implement MONAI preprocessing for 4-channel 3D MRI and 3D tumor masks, document channel order, orientation, spacing, normalization, inversion of spatial transforms, and nearest-neighbor label resampling. Add visual QC tests.
```

nnU-Net | 03

```
Prepare an nnU-Net v2 dataset from audited MSD Task01, preserve and document original label mapping, define WT/TC/ET derived regions using dataset-specific labels, run baseline training/inference only after confirming dataset structure, and export masks in original space.
```

Detection | 04

```
Create a 3D MRI abnormality detection experiment in MONAI. Require real labeled healthy control data alongside abnormal cases; block training if only glioma-positive data exist. Use patient-level split, evaluate AUROC, sensitivity at 90% specificity, ECE and model calibration.
```

Classification | 05

```
Design a closed-set classification experiment using only data-backed classes. Feed features derived from detection and spatial stages, use explicit unsupported/out-of-distribution handling, and export calibrated probabilities with metadata. Do not invent disease labels or validation scores.
```

Offline handoff | 06

```
Package medical model inference as a local Python CLI. Load only local weights. Accept a 3D MRI input directory and generate validated outputs plus provenance and QC flags. Test with networking disabled. Do not build frontend or agent workflows.
```

12. ما الذي لا نعرفه ويجب طلبه من المنظمين؟

- صيغة JSON الرسمية دقيقة الحقول (إن وجدت) وملف Sample Output.
- هل ستدخل الصور كملف NIfTI متعدد القنوات أم مجموعة ملفات لكل Modality؟

- ما مواصفات Inference Environment وحجم GPU وزمن الإقلاع المسموح؟
- المعيار المنشور الرقمي لهلوسة أقل من Threshold، إن كان هناك تحديث خاص.
- تفاصيل وضع حالات غير مدعومة في الـclosed set والتعامل مع Missing Modalities.

13. معايير القبول قبل إخبار الفريق أن عملنا جاهز

- [ ] تشغّلون Dataset Audit بإخراج قابل للتحقق.
- [ ] nnU-Net يخرج Masks حقيقية ذات Spatial Metadata صحيحة.
- [ ] Detection لديه Healthy Controls مثبتة وتقييم حقيقي ومعايرة.
- [ ] Classification لا تدّعي دعم فئات غير مدربة.
- [ ] لكل Metric كود وتقرير وSplit موثق.
- [ ] المخرجات قابلة للاستهلاك محليًا عبر CLI وموثقة.
- [ ] اختبار Offline ناجح دون اتصال وبدون تحميل أوزان أثناء التشغيل.
- [ ] نموذج فشل واضح على Missing/Corrupt/Unsupported Cases.

المراجع

- الوثيقة الرسمية: BrainAgenticthon ACIT26_VF (2).pdf (مواصفات A-D، التقييم، شروط AI المسؤول، التسليم والموعد).
- Task01_BrainTumour/dataset.json كما ظهر في لقطة شاشة المستخدم، وإخراج فحص حالة واحدة.
- MSD: `https://medicaldecathlon.com/`
- MONAI: `https://monai.io/` | nnU-Net v2: `https://github.com/MIC-DKFZ/nnUNet`
- SynthSeg: `https://github.com/BBillot/SynthSeg` | 3D Slicer: `https://www.slicer.org/`

المرجع الرسمي: BrainAgenticthon ACIT26_VF (2).pdf | معلومات MSD المحلية: dataset.json المعروض في المحادثة. لا يتضمن المستند نتائج تجريبية غير مقاسة.